

Cognitive Computing System applicato allo studio del Glioblastoma

Docenti:
Prof. Paolo Maresca

 $\begin{tabular}{ll} Autori: \\ Francesca Lettieri - M63000956 \end{tabular}$

Angelo Russo - M63001016

Guido Maria Secondulfo - M63000927

Indice

1	Intr	troduzione			
	1.1	Traccia	a	2	
2	Architettura 2				
	2.1	Tecnol	ogie utilizzate	2	
		2.1.1	E-utilities	2	
		2.1.2	IBM Cloud Db2	2	
		2.1.3	GitHub	2	
		2.1.4	IBM Cloud Foundry	2	
		2.1.5		3	
		2.1.6		3	
		2.1.7		3	
3	Implementazione 3				
	3.1	Flusso	di esecuzione del sistema globale	3	
	3.2			4	
		3.2.1	E-utilities	4	
		3.2.2		5	
		3.2.3		7	
		3.2.4	· ·	7	
		3.2.5	Funzioni implementate	2	
4	Rife	eriment	ti 1!	5	

1 Introduzione

1.1 Traccia

Il progetto da noi sviluppato si articola in due percorsi distinti:

- Retrieval da PubMed di articoli inerenti al Glioblastoma Multiforme (GBM), creazione di un database atto a contenere le informazioni rilevanti ed, infine, creazione di un modello di NLP (Natural Language Processing) al fine di realizzare un sistema di apprendimento in grado di realizzare una standard meta-analysis accurata.
- 2. Acquisizione delle risonanze magnetiche (MRI) di pazienti affetti da GBM e costruzione di un modello di apprendimento su di esse.

2 Architettura

2.1 Tecnologie utilizzate

2.1.1 E-utilities

Le E-utilities (Entrez Programming Utilities) costituiscono un insieme di 8 programmi server-side che forniscono un'interfaccia stabile per il sistema di database e query Entrez. Le E-utilities utilizzano una sintassi a URL fisso che traduce un insieme di parametri di input nei valori necessari ai componenti software del NCBI per ricercare e recuperare i dati richiesti.

2.1.2 IBM Cloud Db2

IBM Db2 on Cloud è un database cloud transazionale progettato per offrire prestazioni elevate. Esso assicura la scalabilità orizzontale e verticale per soddisfare le richieste di business.

2.1.3 GitHub

Git è un software di controllo versione distribuito utilizzabile da interfaccia a riga di comando, sviluppato per gestire anche progetti di elevate dimensioni con elevate velocità ed efficienza.

2.1.4 IBM Cloud Foundry

Cloud Foundry è una PaaS (platform-as-a-service) open source su IBM Cloud che consente di implementare e scalare le app senza gestire i server. È stato da noi utilizzato al fine di poter eseguire uno script in linguaggio Python all'interno dell'ambiente IBM Cloud.

2.1.5 IBM Watson Machine Learning

IBM Watson Machine Learning aiuta i data scientist e gli sviluppatori ad accelerare l'implementazione di AI e machine-learning. Con i suoi modelli estensibili, aperti, Watson Machine Learning aiuta le aziende a semplificare e sfruttare l'AI in scala su qualsiasi cloud.

2.1.6 fastai

fastai è una libreria di deep learning che fornisce agli operatori componenti di alto livello in grado di fornire rapidamente e facilmente risultati di ultima generazione in domini di deep learning standard, e fornisce ai ricercatori con componenti di basso livello che possono essere mescolati e abbinati per costruire nuovi approcci. fastai mira a fare entrambe le cose senza compromessi sostanziali in facilità d'uso, flessibilità, o prestazioni. Questo è possibile grazie ad un'architettura a strati, che esprime schemi comuni di base di molte tecniche di deep learning e di elaborazione dati in termini di astrazioni disaccoppiate. Queste astrazioni possono essere espresse in modo conciso e chiaro sfruttando il dinamismo del linguaggio Python sottostante e la flessibilità della libreria Pytorch.

2.1.7 Jupyter

Il Progetto Jupyter è un'organizzazione creata per sviluppare software opensource, e supportare ambienti di esecuzione in decine di lingue. JupyterLab offre un'interfaccia per la gestione di documenti di diverso formato, per attività di text editing e attività da terminale.

3 Implementazione

3.1 Flusso di esecuzione del sistema globale

Il diagramma di flusso rappresentante l'elaborazione effettuata è il seguente:

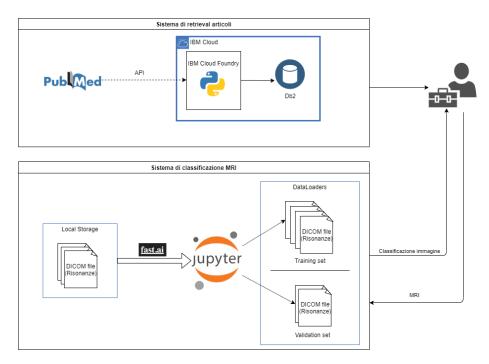


Figura 1: Diagramma di flusso dell'esecuzione

Al fine di agevolare la trattazione, affronteremo i problemi separatamente.

3.2 Flusso di esecuzione del sistema di retrieval degli articoli

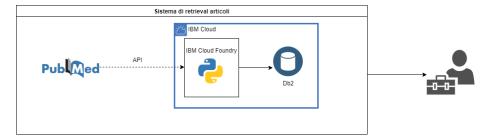


Figura 2: Diagramma di flusso dell'esecuzione

Innanzitutto è stato effettuato il download degli articoli desiderati da PubMed. Dopo una prima elaborazione di tali documenti, essi sono stati memorizzati in un database relazionale all'interno dell'ambiente IBM Cloud.

3.2.1 E-utilities

In seguito ad un confronto con gli esperti di dominio, abbiamo ritenuto opportuno effettuare un retrieval di articoli provenienti unicamente da PubMed, in

quanto source affidabile e attendibile.

A tal fine è stato sviluppato uno script in linguaggio Python (pubmed.py) che, sfruttando le E-utilities, è in grado di effettuare il retrieval degli articoli desiderati da PubMed stesso.

In particolare, la funzione getPubMedIDArticles recupera gli ID degli articoli desiderati da PubMed, in base ai termini specificati. L'implementazione di tale funzione è la seguente:

```
def getPubMedIDArticles(query):
    test = "esearch.fcgi?db=pubmed"
    term = "&term="+query #query della ricerca
    maxArts = "&retmax = 100000" #Numero massimo di articoli
        recuperati dalla ricerca
    link = "https://eutils.ncbi.nlm.nih.gov/entrez/eutils
        /%22+test+term+maxArts

s = urllib.request.urlopen(link)
    contents = s.read()
    file = open("export_idArticles.xml", 'wb')
    file.write(contents)
    file.close()
```

3.2.2 Query di ricerca

La query effettuata è stata elaborata dagli esperti di dominio. Essa espone quali siano i termini da ricercare all'interno di tutti i campi di un articolo, inclusi i MeSH Terms ¹ associati all'articolo stesso.

I criteri di inclusione per la selezione degli articoli sono i seguenti:

- Studi randomizzati di confronto fra trattamenti;
- Fase II o III (compresi studi Fase I/II purchè contengano risultati adeguati della Fase II;
- OS sopravvivenza globale (overall survival) e PFS sopravvivenza libera da progressione (progression free survival) e ORR (Overall Response Rate) Tasso di risposta complessiva;
- Solo Glioblastoma multiforme (GBM) o High Grade Glioma in ripresa dopo pregressa chirurgia e terapia adiuvante o in progressione.

I criteri di esclusione per la selezione degli articoli sono, invece, i seguenti:

¹Medical Subject Headings (acronimo: MeSH) è un enorme vocabolario controllato (o sistema di metadati) ideato con l'obiettivo di indicizzare la letteratura scientifica in ambito biomedico. Il tesauro è stato creato dalla National Library of Medicine (NLM) degli Stati Uniti, che è responsabile anche della sua gestione. Il MeSH viene adoperato per l'indicizzazione degli articoli delle oltre 5000 riviste mediche presenti nel database bibliografico Medline/PubMed e nel catalogo dei libri della NLM. Il vocabolario può essere consultato e scaricato gratuitamente da tutti gli utenti di internet. La stampa dell'edizione cartacea è stata abbandonata nel 2007.

- Tumori pediatrici;
- Studi non randomizzati;
- Studi a singolo braccio;
- Studi di fase I;
- GBM in trattamento adiuvante;
- Review/metanalisi;
- Studi preclinici;
- Studi di farmacoeconomia;
- Studi di confronto senza analisi statistiche.

La formulazione risultante della query è, dunque, la seguente:

(glioblastoma OR glioblastoma multiforme OR anaplastic astocytoma OR malignant glioma OR high grade glioma OR high grade astrocytoma) AND (diffuse OR multiple OR unresectable OR advanced OR reccurent OR inoperable OR disseminated OR progressive OR relapsed) AND (clinical outcome OR OS OR PFS OR ORR) AND (chemotherapy OR target Therapy OR immunotherapy OR cyclophosphamide OR bevacizumab OR temozolomide OR irinotecan OR carmustine OR lomustine OR nitrosourea OR BCNU OR CCNU OR carboplatin OR cisplatin OR platinum OR PCV OR etoposide OR VP-16 OR cilengitide OR alternating electric field therapy OR TTF OR tumor treating fields OR procarbazine OR vincristine OR sunitinib OR lapatinib OR pazopanib OR temsirolimus OR everolimus OR fotemustine OR sagopilone OR Bortezomib OR Vorinostat OR enzastaurin OR Vandetanib OR veliparib OR dasatinib OR ultrafractionated RT OR nivolumab OR Regorafenib OR pembrolizumab OR ipilimumab OR radiosurgery OR ypo-fractioned radiation OR anlotinib OR Cesium-131 brachytherapy OR gefitinib OR sorafenib OR dacomitinib OR pidilizumab OR ivosidenib OR Interstitial brachytherapy OR erlotinib OR depatuxizumab mafodotin OR durvalumab OR onartuzumab OR rituximab OR Disulfiram OR reirradiation OR capmatinib OR buparlisib OR drug delivery tecnology OR convection-enhanced delivery OR bulk flow OR intra-arterial chemotherapy OR nanotechnology-based controlled delivery OR intraoperative polymer implants OR dagnetic cationic microsphere OR biodegradable polymer wafers OR lipid-coated microbubbles OR magnetic hyperthermia OR photodynamic therapy)

Figura 3: Query originale

Tale query è stata, quindi, da noi raffinata al fine di poter effettuare il retrieval degli articoli che soddisfacessero i criteri richiesti.

L'operazione di raffinamento è stata dettata dalla risposta delle API di PubMed a determinati termini (es. "ypo-fractioned", "dagnetic") che facevano parte della query iniziale; tali termini, omessi in fase di raffinamento, non risultavano presenti all'interno del tesauro (i.e. il MeSH).

(glioblastoma+OR+glioblastoma+multiforme+OR+anaplastic+astocytoma+OR+malignant+glioma+OR+high+grade+glioma+OR+high+grade+astrocytoma)+AND+(diffuse+OR+multiple+OR+unresectable+OR+advanced+OR+reccurent+OR+inoperable+OR+disseminated+OR+progressive+OR+relapsed)+AND+(clinical+outcome+OR+OS+OR+PFS+OR+ORR)+AND+(chemotherapy+OR+target+Therapy+OR+immunotherapy+OR+cyclophosphamide+OR+bevacizumab+OR+temozolomide+OR+irinotecan+OR+carmustine+OR+lomustine+OR+nitrosourea+OR+BCNU+OR+CCNU+OR+carboplatin+OR+cisplatin+OR+platinum+OR+PCV+OR+etoposide+OR+VP-

16+OR+cilengitide+OR+alternating+electric+field+therapy+OR+TTF+OR+tumor+treating+fields+OR+procarbazine+OR+vincristine+OR+sunitinib+OR+lapatinib+OR+pazopanib+OR+temsirolimus+OR+everolimus+OR+fotemustine+OR+sagopilone+OR+Bortezomib+OR+Vorinostat+OR+enzastaurin+OR+Vandetanib+OR+veliparib+OR+dasatinib+OR+ultrafractionated+RT+OR+nivolumab+OR+Regorafenib+OR+pembrolizumab+OR+ipilimumab+OR+radiosurgery+OR+ypo-

fractioned+radiation+OR+anlotinib+OR+Cesium-

131+ brachy the rapy+OR+gefit in ib+OR+sorafen ib+OR+da comit in ib+OR+pid ilizumab+OR+ivos iden ib+OR+Interstit ial+brachy the rapy+OR+er lot in ib+OR+depatux izumab+ma fodot in+OR+durvalumab+OR+on artuzumab+OR+ritux imab+OR+Disul firam+OR+reir radiation+OR+cap matin ib+OR+bupar lisib+OR+drug+delivery+tecnology+OR+convection-enhanced+delivery+OR++bulk+flow+OR+intra-arterial+chemother apy+OR+nanotechnology-

based + controlled + delivery + OR + intraoperative + polymer + implants + OR + dagnetic + cationic + microsphere + + OR + biodegradable + polymer + wafers + OR + lipid -

coated+microbubbles+OR+magnetic+hyperthermia+OR+photodynamic+therapy)

Figura 4: Query Raffinata

In entrambi i casi, il numero di articoli recuperati è pari a 1'318, per questo l'eliminazione dei termini è risultata ininfluente per quanto riguarda il risultato finale ottenuto. Un ulteriore filtraggio degli articoli recuperati è stato fatto in base alla data di pubblicazione, secondo quanto richiesto e consigliato dagli esperti di dominio: escludendo gli articoli pubblicati prima del 1990, il numero finale di articoli recuperati è pari a 1'313.

3.2.3 GitHub e IBM Cloud Foundry

Per poter importare gli articoli in ambiente IBM Cloud, innanzitutto è stato creato un repository su GitHub all'interno del quale è stato memorizzato il file pubmed.py.

In particolare, sono state effettuate le operazioni di **add**, **commit** e **push** del file all'interno del repository attraverso il prompt dei comandi.

3.2.4 IBM Cloud Db2

Innanzitutto è stata istanziata una versione lite del Database Db2. Utilizzando le credenziali di accesso fornite dal sistema e le API IBM_DB, è stato possibile accedere al Database attraverso una funzione all'intero del file *pubmed.py*. Per la modellazione del database, volendo tener traccia di un'unica entità, gli articoli, è stato realizzato il seguente diagramma ER:

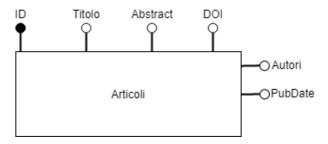


Figura 5: Diagramma ER

Abbiamo ipotizzato di memorizzare, per ogni articolo:

- DOI (Digital Object Identifier) quando disponibile;
- ID dell'articolo nel database PubMed;
- Titolo;
- Lista di autori quando disponibile;
- Data di pubblicazione quando disponibile;
- Rivista di pubblicazione quando disponibile;
- Abstract quando disponibile.

Osserviamo che, durante l'attività di recupero dalle API Pubmed, il DOI era assente in alcuni articoli, il che lo rendeva inadeguato al ruolo di chiave primaria dell'entità. Per questo motivo, abbiamo utilizzato un ulteriore identificativo numerico con auto-incremento come chiave primaria.

Quindi, è stato possibile creare una tabella ARTICOLI attraverso la seguente query:

```
CREATE TABLE articoli (
id INTEGER NOT NULL PRIMARY KEY GENERATED ALWAYS AS
IDENTITY (START WITH 1 INCREMENT BY 1),
pubmedId INTEGER UNIQUE NOT NULL,
doi VARCHAR(80),
titolo VARCHAR(1000),
autori VARCHAR(5000),
dataPubblicazione DATE,
abstract VARCHAR(10000),
nomeRivista VARCHAR (1000)"
```

La connessione al database è realizzata attraverso la funzione *connectionDB2*, mentre tale connessione viene chiusa attraverso la funzione *endConnectionDB2*. L'implementazione di entrambe le funzioni è riportata di seguito:

```
def connectionDB2():
    conn_info = ""DATABASE=BLUDB;HOSTNAME=dashdb-txn-sbox
        -yp-lon02-13.
    services.eu-gb.bluemix.net;PORT=50000;PROTOCOL=TCPIP;
    UID=xxd26106;PWD=s5bzk6p^3s94hght;""
    conn = ibm_db.connect(conn_info, "", "")
    return conn

def endConnectionDB2(conn):
    ibm_db.close(conn)
```

Si noti che le informazioni relative al Database, quali nome dello stesso, l'Hostname, il porto, il protocollo, l'username e la password, sono strettamente legate all'account IBM Cloud che ha istanziato il database. In caso di migrazione del database, o di creazione di uno nuovo, è necessario modificare l'intera variabile $conn_info$ con le rispettive Credenziali di Servizio generate sul portale IBM Cloud.

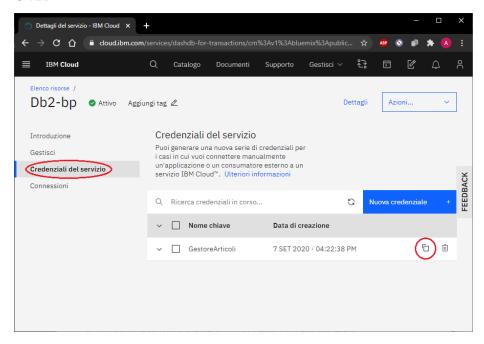


Figura 6: Schermata DB2 per ottenere le credenziali del servizio

Infine, il popolamento del database può essere effettuato attraverso due diverse funzioni. La prima, *insertArticleDB2*, inserisce un singolo articolo all'interno del database attraverso la seguente query sql:

```
VALUES (valore_pubmedId , valore_doi , valore_titolo ,
    valore_autori ,
    valore_dataPubblicazione , valore_abstract ,
        valore_nomeRivista);
```

La seconda, insertArrayDB2, è quella che è stata utilizzata per realizzare il primo popolamento del database. Essa riceve in ingresso un array di articoli, andando ad inserire ognuno di essi nel database stesso attraverso la stessa query vista precedentemente.

In entrambi i casi, si è resa, quindi, necessaria la definizione di una classe Articolo, la cui implementazione è riportata di seguito:

```
class Articolo():
    def __init__(self, titolo, autori, pubDate, pubMedId,
         doi, abstract, journalTitle):
        self.titolo = titolo
        self.autori = autori
        self.abstract = abstract
        self.doi = doi
        self.pubMedId = pubMedId
        self.pubDate = pubDate
        self.journalTitle = journalTitle
    \mathbf{def} = \mathbf{str} = (\mathbf{self}):
        return "PUBMED ID: %s\nDOI: %s\nTitolo: %s\
            nAutori: %s\nData di Pubblicazione: %s\
            nAbstract: %s\nJournal Title: %s\n\n" % (self.
            pubMedId, self.doi, self.titolo, ', '.join(
            self.autori), self.pubDate, self.abstract,
            self.journalTitle)
```

L'implementazione delle funzioni sopra menzionate è la seguente:

```
jtitle_temp = articolo.journalTitle.replace("'",
     insert = ibm_db.exec_immediate(conn, "INSERT INTO
         articoli (pubmedId, doi, titolo, autori,
         dataPubblicazione, abstract, nomeRivista) VALUES
         ('"+articolo.doi+"', '"+titolo_temp+"', '"+
autori_insert+"', '"+ articolo.pubDate+"', '"+
abstract_temp+"', '"+jtitle_temp+"'')")
     print("["+str(i)+"] - Inserito\n") #DEBUG dell'
         articolo inserito
def insertArrayDB2 (articoli):
     for articolo in articoli:
          abstract_temp = " "
          titolo_temp = ""
          jtitle_temp = ""
          autori_insert = ', '.join(articolo.autori)
          if (autori_insert != None):
               autori_insert = autori_insert.replace("'", "
          if (articolo.titolo! = None):
               titolo_temp = articolo.titolo.replace("',", "
                    , , ,, )
          if (articolo.abstract != None):
               abstract_temp = articolo.abstract.replace("',"
                   , ", ', ")
          if (articolo.journalTitle != None):
               jtitle_temp = articolo.journalTitle.replace("
                   ", ", ")
          insert = ibm_db.exec_immediate(conn, "INSERT INTO
                articoli (pubmedId, doi, titolo, autori,
              \label{localization} \begin{array}{lll} dataPubblicazione\;,\;\; abstract\;,\;\; nomeRivista\;)\\ VALUES\;\; (\;"+articolo\;.doi+"\;',\;\; "+titolo\_temp+"\;',\;\; \end{array}
              '"+ autori_insert+"', '"+ articolo.pubDate+"
', '"+abstract_temp+"', '"+jtitle_temp+"'')")
          print("["+str(i)+"] - Inserito\n") #DEBUG dell'
              articolo inserito
```

Inizialmente, si era pensato di mantenere in memoria le informazioni degli articoli recuperati, per poi caricarle tutte insieme sul database: questo metodo però è risultato poco efficiente a causa della grande mole di articoli da caricare. Tale risultato è stato ottenuto stressando il sistema tramite una query generica di prova, che ricercasse gli articoli che contenessero in qualsiasi campo (sia esso Titolo, MeSH o Abstract) il termine "glioblastoma". Questa query di prova ha prodotto come risultato ben 41'364 articoli e pubblicazioni, rallentando di molto il processo di recupero, il mantenimento temporaneo in memoria e infine l'inserimento nel Database degli stessi. È risultato molto più conveniente, piuttosto, gestire grosse moli di articoli recuperandoli e inserendoli immediatamente nel database, in modo da non perdere l'eventuale cluster di articoli in caso di disconnessioni causate dal server di PubMed (problema che, più volte, è stato riscontrato durante il testing dello script). Conviene utilizzare, quindi, la funzione insertArrayDB2 quando vengono recuperati quantità minime di articoli (nell'ordine massimo delle centinaia), come nel caso della query utilizzata ed esposta nel sottoparagrafo 3.1.2, dove la query ha restituito 1'318 articoli come esito della ricerca.

3.2.5 Funzioni implementate

Dopo aver ottenuto la lista contenente gli ID degli articoli, la funzione pubMedIDConverter recupera le informazioni ad essi associate. L'implementazione di tale funzione è la seguente:

```
def PubMedIdConverter(articoli):
    data_{-}file = 'export.xml'
    tree = ET. parse (data_file)
    root = tree.getroot()
    id_converter = "https://eutils.ncbi.nlm.nih.gov/
       entrez/eutils/efetch.fcgi?db=pubmed&id="
    i = 0
    for child in root.findall("./IdList/Id"):
        i=i+1
        id = child.text
        id_converter1 = id_converter+id+"&retmode=xml"
        xml = urllib.request.urlopen(id_converter1).read
        xml_tree = ET. fromstring (xml)
                                          # Root
        for child2 in xml_tree.findall("PubmedArticle"):
            temp_title = ""
            temp_abstract = ""
            temp_author = ""
            temp_doi = "Mancante"
            temp_pubdate = ""
```

```
autori_vector = []
for child2_0 in child2.findall("
   MedlineCitation / Article"):
    for child2_JournalTitle in child2_0.
       findall ("Journal/Title"):
        temp_jtitle = child2_JournalTitle.
           text
    for child2_1 in child2_0.findall("
       Article Title"):
        temp\_title = child2\_1.text
    for child2_2 in child2_0.findall("
       Abstract/AbstractText"):
        temp_abstract = child2_2.text
   for child2_3 in child2_0.findall("
       AuthorList/Author"):
        #La presente soluzione e' concepita
            nel caso si voglia tenere traccia
           solo\ di\ iniziali\ del\ nome\ e
           cognome (per intero)
        path_cognome = child2_3.find("
           LastName")
        path_iniziali = child2_3.find("
            Initials")
        if (path_cognome != None):
            if (path_iniziali != None):
                temp_author = child2_3.find("
                    LastName").text +" "+
                    path_iniziali.text+"."
            else:
                temp_author = child_{2-3}. find ("
                    LastName").text
        autori_vector.append(temp_author)
for child2_4 in child2.findall("PubmedData"):
    for child2_5 in child2_4.findall("History
       /PubMedPubDate/[@PubStatus='entrez']")
        temp_pubdate = child_{2-5}[0].text+"-"+
           child_{2-5}[1].text+"-"+child_{2-5}[2].
           text
    childFinale = child2_4.find("
       ArticleIdList/ArticleId/[@IdType='doi
        "]")
    if (childFinale != None):
        temp_doi = childFinale.text
```

4 Riferimenti

- E-utilities: https://www.ncbi.nlm.nih.gov/books/NBK25501/;
- IBM Cloud Db2: https://www.ibm.com/it-it/cloud/db2-on-cloud;
- IBM Cloud Foundry: https://www.ibm.com/it-it/cloud/cloud-foundry;
- GitHub: https://github.com;
- MeSH: https://it.wikipedia.org/wiki/Medical_Subject_Headings;
- Jupyter: https://jupyter.org;